



UNIVERSITÉ DE TECHNOLOGIE DE BELFORT-MONTBÉLIARD

Module PF22 — Apprentissage profond

Réduction des Coûts d'Apprentissage par Approche Multi-Fidélité

Le constat

- ▶ La performance d'un réseau dépend de la **quantité** et de la **qualité** des données.
- ▶ Données **Haute Fidélité** : haute résolution, experts, capteurs chers → **rare et coûteuses**.
- ▶ Données **Basse Fidélité** : dégradées, web, capteurs bas de gamme → **abondantes et bon marché**.


L'idée : l'apprentissage multi-fidélité

- ▶ Mélanger un *petit* volume HF avec un *grand* volume BF.

Problématique. Comment exploiter beaucoup de données BF bon marché pour **maximiser la précision sur le domaine HF**, tout en **minimisant le coût d'acquisition** ?

Etude réalisée sur de la classification d'images

Concrètement : Haute Fidélité vs Basse Fidélité



Dégradation BF canonique

Sous-échantillonnage

224 → 64 px

+ bruit gaussien $\sigma = 0,15$

+ compression **JPEG** q60

Appliquée à la volée et
déterministe par image (train BF =
test BF, pas de décalage parasite).

3 datasets de natures différentes (animaux, races fine-grained, scènes) pour valider la généralité.

Découpage des données

- ▶ Test **10 %** (100 % HF) ; Train **90 %**.
- ▶ Train découpé en **10 % HF + 90 % BF**.

Évaluation croisée

- ▶ 3 jeux de test : **HF, BF, Mixte**.
- ▶ Critère prioritaire : **Test HF**.

Rigueur & reproductibilité

- ▶ Modèle : **ResNet-18 *from scratch***.
- ▶ **3 datasets** × **3 seeds** → moyenne ± écart-type.
- ▶ Dégradation centralisée & déterministe.
- ▶ Calcul sur **serveur GPU V100S**.

Tout résultat est reporté en **moyenne ± écart-type** sur 3 seeds → conclusions robustes au hasard d'initialisation.

Trois métriques distinctes

- ▶ **Coût donnée** : acquisition, payé *une fois*.
- ▶ **Coût calcul** : images vues à l'entraînement.
- ▶ **Coût total** : calcul pondéré par le coût donnée.

Formule du coût unitaire (résolution d)

$$C(d) = C_{\min} + (C_{\text{HF}} - C_{\min}) \left(\frac{d}{224} \right)^2$$

Calibration : **HF = 10, BF (64 px) = 1** $\Rightarrow$ ratio de coût **10 : 1**.

Exemple — Animals-10

Pool d'entraînement :
2 352 HF + 21 213 BF

$$\underbrace{2\,352 \times 10}_{\text{HF}} + \underbrace{21\,213 \times 1}_{\text{BF}} = \mathbf{44\,733\ CA}$$

C'est le **coût donnée** commun à toute méthode utilisant le pool complet.

Les méthodes se départagent alors sur le **coût total** (passages sur le HF coûteux).

Modèles de référence (Baselines)

Baseline (Animals-10)	Test HF	Test BF	Coût donnée
BL 1 — Premium (HF seul)	54,3 $\pm$ 2,2	27,8 $\pm$ 0,8	23 520
BL 2 — Low-Cost (BF seul)	61,3 $\pm$ 6,3	71,0 $\pm$ 1,5	21 213
BL 3 — Mixte (borne haute)	74,0 $\pm$ 3,0	72,9 $\pm$ 1,1	44 733

Effondrement face au bruit

BL 1 (HF seul) : **54,3 %** $\rightarrow$ **27,8 %** sur BF. Le *domain shift*.

Paradoxe de la quantité

BL 2 (BF seul) bat BL 1 **même sur HF** (61,3 vs 54,3 %) pour un coût *inférieur*.

BL 3 (Mixte) = borne supérieure à atteindre... mais coûteuse. **Objectif : l'égaliser à moindre coût.**

Quatre stratégies multi-fidélité (objectif HF)

S1 · Transfer Learning séquentiel

Pré-entraînement sur le volume **BF**, puis **fine-tuning** sur le sous-ensemble **HF**. ($BF \rightarrow HF$)

S2 · Co-training pondéré

HF et BF dans **chaque batch**, avec une **pondération** de la perte favorisant le HF.

S3 · Curriculum Learning

Un seul entraînement où la **proportion de HF augmente par paliers** ($0\% \rightarrow 100\%$).
Transition douce.

S4 · EWC (Elastic Weight Consolidation)

Transfert séquentiel + **pénalité de Fisher** protégeant les poids importants pour le BF (anti-oubli).

Chaque stratégie est aussi déclinée en version **optimisée par Optuna**.

Résultats — synthèse globale (BL 3 + 4 stratégies)

Modèle	HF	BF	Mixte	Coût donnée	Coût total
<i>Animals-10</i>					
BL 3 (Mixte)	74,0 ±3,0	72,9 ±1,1	73,4 ±2,0	44 733	894 660
Stratégie 1	77,7 ±0,6	68,3 ±0,5	73,0 ±0,3	44 733	400 230
Stratégie 2	63,8 ±5,2	61,0 ±4,2	62,4 ±4,7	44 733	486 720
Stratégie 3	76,5 ±0,2	73,1 ±0,1	74,8 ±0,1	44 733	421 265
Stratégie 4 (EWC)	78,0 ±0,3	68,8 ±0,7	73,4 ±0,4	44 733	400 230
<i>Imagewoof</i>					
BL 3 (Mixte)	50,3 ±2,5	48,8 ±2,3	49,6 ±2,4	17 116	342 320
Stratégie 1	51,0 ±1,6	44,7 ±1,3	47,9 ±1,5	17 116	153 160
Stratégie 2	37,5 ±0,8	37,4 ±0,3	37,5 ±0,2	17 116	183 040
Stratégie 3	47,5 ±1,4	46,1 ±1,1	46,8 ±1,2	17 116	158 880
Stratégie 4 (EWC)	53,3 ±0,7	46,8 ±0,6	50,0 ±0,6	17 116	153 160
<i>Intel</i>					
BL 3 (Mixte)	82,8 ±1,2	82,1 ±1,2	82,5 ±1,2	26 652	533 040
Stratégie 1	86,1 ±0,4	79,1 ±1,4	82,6 ±0,7	26 652	238 420
Stratégie 2	82,0 ±1,0	79,8 ±0,9	80,9 ±0,9	26 652	291 200
Stratégie 3	84,6 ±1,0	82,6 ±1,5	83,6 ±1,2	26 652	250 880
Stratégie 4 (EWC)	85,8 ±0,4	80,0 ±0,9	82,9 ±0,6	26 652	238 420

En gras : meilleur **Test HF** par dataset. Coût *donnée* identique (pool complet) ; les stratégies se départagent sur le **coût total**.

Méthode

- ▶ Recherche bayésienne (TPE), **20 essais** par stratégie $\times$ dataset.
- ▶ Objectif : précision de validation HF.

Ce qu'on apprend

- ▶ Gros gains sur les stratégies **instables** : Co-training **+9,4 pts** (Animals), Curriculum **+5,3 pts** (Imagewoof).


Limite observée

Peu — voire pas — de gain sur les stratégies **déjà fortes et stables** (S1, EWC) : EWC se dégrade même (λ trop relâché), signe d'un léger sur-ajustement à la validation (budget de 20 essais).

Piste : optimisation **multi-objectif** (précision *et* coût) avec plus d'essais.

Résultats — précision HF par modèle




Précision Test HF par modèle (moyenne $\pm$ std, 3 seeds)



Légende des figures : « S5 » = EWC = Stratégie 4 ; « S3 » = Curriculum = Stratégie 3.

Résultats — le compromis coût / performance

Pareto : coût total vs précision HF




Les stratégies forment la **frontière efficace** : on **dépasse** la borne haute (BL 3) sur HF tout en **divisant le coût total par ≈ 2** (Animals : 400 230 vs 894 660 CA, à coût *donnée* identique).

Robustesse à la dégradation

Évaluation sur des données *encore plus* dégradées que l'entraînement (résolution ↓, bruit ↑) :

- ▶ Arbitrage **précision-propre vs robustesse**.
- ▶ EWC / S1 : meilleurs sur données *propres*.
- ▶ **Curriculum : le plus robuste** sous forte dégradation.
- ▶ BL 2 (BF) : robuste à la perte de résolution, mais fragile au bruit fort.

Robustesse à la dégradation — Animals-10



Exemple Animals-10 — résolution (gauche), bruit (droite). « S5 » = EWC, « S3 » = Curriculum.

La supériorité des stratégies multi-fidélité en **précision HF** est confirmée sous **multi-graines** et sur les **3 datasets**.

EWC $\gtrsim$ Transfer Learning > Curriculum > Co-training $\ggg$ baselines

À retenir

- ▶ Objectif **atteint** : on dépasse le mélange naïf coûteux **à moitié prix**.
- ▶ *Domain shift* et *paradoxe de la quantité* confirmés.
- ▶ Résultats **cohérents** sur 3 datasets, multi-graines.

Perspectives

- ▶ Optuna **multi-objectif** (précision et coût).
- ▶ Autres **architectures** de réseau (ResNet-34, EfficientNet. . .).
- ▶ **Élargissements** : plus de datasets, de stratégies, de niveaux de fidélité, plus d'époques et d'essais Optuna.

Des données bon marché et imparfaites : non pas un pis-aller, mais un véritable levier.



Merci de votre attention

Questions & discussion
